

吴操

求职意向: AI infra、LLM 推理 | +86 15882372901 | wucao20000102@gmail.com

教育背景

米兰理工大学 意大利 Top1, QS 87

高性能计算工程硕士

米兰, 意大利

2024 年 9 月 – 2027 年 3 月

四川大学 985

计算机科学与技术学士

成都, 中国

2018 年 9 月 – 2022 年 6 月

工作经历

哔哩哔哩

Golang 后端开发工程师 (全职)

上海, 中国

2022 年 7 月 – 2024 年 8 月

- 使用 Go、MySQL、Redis、Kafka、Hive、ClickHouse 参与直播业务结算核心服务开发。
- 入职一年内完成晋升, 成为主播结算系统主要开发者之一, 在职期间支持累计超 13 亿元人民币奖励金的结算链路处理。

项目经历 (推理相关)

A Simplified vLLM Core

个人项目

LLM 推理系统

2025 年 12 月 – 2026 年 5 月

- 基于 PyTorch/CUDA 从零实现简化版 vLLM 推理核心, 完成 Engine、Scheduler、BlockManager 等模块搭建, 打通 LLM 请求调度与执行链路。
- 实现 Paged KV Cache、Continuous Batching 与 prefill/decode 混合调度, 支持多请求离线并发推理。
- 实现 AWQ 量化并深入理解其基本原理, 显著降低模型权重存储开销。

Scheduling for Expert Movement in vLLM's EPLB

毕业设计 (进行中)

米兰理工大学

2026 年 5 月 – 至今

- 在 vLLM 的 MoE 专家并行负载均衡 (EPLB) 重平衡阶段, 针对专家迁移 (Expert Weight Migration) 中单个 rank 同时承担多对 P2P 传输的并发热点问题, 设计迁移批调度机制, 在保持最终 expert placement 一致的前提下, 将迁移请求重新组织为无冲突批次, 降低 rank 级别热点及其引发的 NIC 拥堵。
- 问题建模与策略: 基于 EPLB 重平衡前后的全局 expert index 映射, 将远程迁移抽象为端点冲突受限的 batching 问题; 设计并实现两种贪心策略, 其中 degree_desc 按端点度数降序优先处理, 在典型热点场景下可逼近 ILP 给出的最优 batch 数。
- vLLM 集成: 将迁移调度能力嵌入 vLLM 的 EPLB 重平衡执行路径, 新增可配置开关 (如 batching 开关、策略选择、最大 batch 数软限制), 保证与原有全并发模式兼容; 后续计划在真实 GPU 集群上测试该方案对 rank 热点和在线推理延迟稳定性的影响。

获奖经历

- 2021 ACM 算法集训队队员 (32 人之一), 四川大学
- 2021 年 4 月 西南赛区二等奖 (前 15%), 中国大学生计算机设计大赛
- 2021 年 10 月 省二等奖 (前 20%), 蓝桥杯 C/C++ 程序设计竞赛
- 2020 年 10 月 银奖 (前 10%), 中国大学生程序设计挑战赛

技能

语言与框架 Python, C++, CUDA, C, Go, PyTorch, Hugging Face

LLM 推理 KV Cache, PagedAttention, FlashAttention, Continuous Batching, AWQ, TP, EP, DP, MoE, EPLB, vLLM, Transformers, Qwen

CUDA Kernel GEMV, GEMM, Softmax, MaxReduce, SumReduce, Transpose; 掌握访存合并、向量化访存等 IO-Bound 优化技巧, 以及 Tiling 等 Latency-Bound 优化技巧

个人介绍

本人创立并独立开发、运营用户数 10w+ 的微信小程序 GrowYumi (至今仍在运行), 拥有 两年全职 开发经验, 具备良好的工程意识; 性格开朗, 沟通协作顺畅, 大学期间曾组建乐队并夺得校级足球冠军; 期待融入新的团队, 与大家共同进步。