

吴操

求职意向: AI infra、LLM 推理 | +86 15882372901 | wucaozhao20000102@gmail.com

教育背景

米兰理工大学 意大利 Top1, QS 87

高性能计算工程硕士

米兰, 意大利

2024 年 9 月 – 2027 年 3 月

四川大学 985

计算机科学与技术学士

成都, 中国

2018 年 9 月 – 2022 年 6 月

工作经历

壁仞科技

大模型推理工程师 (实习)

杭州, 中国

2026 年 8 月 – 至今

- GLM-5.2 算子融合方案设计**: 调研 GLM-5.2 在 vLLM 与 SGLang 中的开源算子融合实现, 梳理融合边界、数据流与关键算子, 并据此设计 TensorRT-LLM-Supa 的 GLM-5.2 算子融合方案。
- Triton 生态接入 CPP 推理框架方案设计**: 为使 TensorRT-LLM-Supa 复用 Triton 算子生态, 调研 C++ 后端接入 Triton 的技术路径并完成落地; 完成单层 (1 Layer) 精度测试及组内技术分享。

哔哩哔哩

Golang 后端开发工程师 (全职)

上海, 中国

2022 年 7 月 – 2024 年 8 月

- 使用 Go、MySQL、Redis、Kafka、Hive、ClickHouse 参与直播业务结算核心服务开发。
- 两年内迅速成长, 成为哔站主播结算系统主要开发者之一, 在职期间支持累计超 13 亿元人民币奖励金的结算链路处理。

项目经历 (推理相关)

Scheduling for Expert Movement in vLLM's EPLB

米兰理工大学

毕业设计 / vLLM 开源贡献

2026 年 5 月 – 2026 年 10 月

- 项目概述**: 针对异步 EPLB 专家迁移与在线推理争抢网络带宽、拉高服务延迟的问题, 设计并实现 contention-aware 专家迁移批调度机制。vLLM PR #52641 已于 2026 年 10 月合入主分支, **该优化已被 vLLM 合入, 成为 vLLM 官方特性**。
- 调度设计**: 按源/目标 rank 组织迁移并拆分为无冲突批次, 使每个 rank 在单批次内至多与一个对端通信, 同时保留互不冲突 rank 对之间的并发传输, 降低 rank 级通信热点与 NIC 瞬时拥塞。
- 工程集成**: 将调度器集成至 vLLM 异步 EPLB/NIXL 迁移链路; 在每次重平衡周期中一次性生成全部 48 个 MoE Layer 的调度计划, 迁移仍按 Layer 执行, 在控制网络竞争的同时降低 Python 调度开销, 并保持同步 EPLB 原有路径不变。
- 性能收益**: 在 4 节点、TP=4、32 并发的 Qwen3-30B-A3B 在线服务测试中, 请求吞吐提升 **2.28%**; TTFT P50/P99 降低 **1.18%/1.30%**, TPOT P50/P99 降低 **1.94%/0.87%**, E2EL P50/P99 降低 **3.18%/1.50%**; NIC 流量 P99 降低 **10.24%**, 调度总开销仅为节省服务时间的 **0.285%**。

获奖经历

2021 ACM 算法集训队队员 (32 人之一), 四川大学

2021 年 4 月 西南赛区二等奖 (前 15%), 中国大学生计算机设计大赛

2021 年 10 月 省二等奖 (前 20%), 蓝桥杯 C/C++ 程序设计竞赛

2020 年 10 月 银奖 (前 10%), 中国大学生程序设计挑战赛

技能

语言与框架 Python, C++, CUDA, C, Go, PyTorch, Hugging Face

LLM 推理 KV Cache, PagedAttention, FlashAttention, Continuous Batching, AWQ, TP, EP, DP, MoE, EPLB, vLLM, Transformers, Qwen

CUDA Kernel GEMV, GEMM, Softmax, MaxReduce, SumReduce, Transpose; 掌握访存合并、向量化访存等 IO-Bound 优化技巧, 以及 Tiling 等 Latency-Bound 优化技巧

个人介绍

本人创立并独立开发、运营用户数 **10w+** 的微信小程序 GrowYumi (至今仍在运行), 拥有 **两年全职** 开发经验, 具备良好的工程意识; 性格开朗, 沟通协作顺畅, 喜欢团队协作, 大学期间曾组建乐队也夺得校足球冠军; 期待融入新的团队, 与大家共同进步。