

吴操

求职意向: AI infra、LLM 推理 | +86 15882372901 | wucaozhao20000102@gmail.com

教育背景

米兰理工大学 意大利 Top1, QS 87

高性能计算工程硕士

2024 年 9 月 – 2026 年 12 月

四川大学 985

计算机科学与技术学士

成都, 中国

2018 年 9 月 – 2022 年 6 月

工作经历

哔哩哔哩

Golang 后端开发工程师 (全职)

上海, 中国

2022 年 7 月 – 2024 年 8 月

- 使用 Go、MySQL、Redis、Kafka、Hive、ClickHouse 参与直播业务结算核心服务开发。
- 入职一年内完成晋升, 成为主播结算系统主要开发者之一。
- 在职期间支持累计超 13 亿元人民币奖励金的结算链路处理。

项目经历

A Simplified vLLM Core

个人项目

LLM 推理系统

2025 年 12 月 – 2026 年 5 月

- 基于 PyTorch/CUDA 从零实现简化版 vLLM 推理核心, 完成 Engine、Scheduler、BlockManager 等模块搭建, 打通 LLM 请求调度与执行链路。
- 实现 Paged KV Cache、Continuous Batching 与 prefill/decode 混合调度, 支持多请求离线并发推理。
- 实现 AWQ 量化, 降低模型权重存储开销。

Possible Optimizations for MoE Inference in vLLM

毕业设计 (进行中)

米兰理工大学

2026 年 5 月 – 至今

- 研究 Scheduling For Experts Movement: 在 EPLB 中发生 Expert 迁移时, 在不改变算法结果的前提下, 对同一批 Batch 重新组合以缓解 Hotspot; 目前已完成 ILP 建模并证明可得到更优组合, 后续将在真实 GPU 集群上测试。
- 研究在 EPLB 迁移阶段降低 Expert 迁移优先级, 以提升推理吞吐、尾延迟稳定性与在线服务连续性; 这一 Feature 的主要难点不在代码实现, 而在实验设计与 A/B 对齐。

获奖经历

- 2021 ACM 算法集训队队员 (32 人之一), 四川大学
- 2021 年 4 月 西南赛区二等奖 (前 15%), 中国大学生计算机设计大赛
- 2021 年 10 月 省二等奖 (前 20%), 蓝桥杯 C/C++ 程序设计竞赛
- 2020 年 10 月 银奖 (前 10%), 中国大学生程序设计挑战赛

技能

语言与框架 Python, C++, CUDA, C, Go, PyTorch, Hugging Face

LLM 推理 KV Cache, PagedAttention, Continuous Batching, AWQ, TP, EP, DP, vLLM, Transformers, Qwen

CUDA Kernel GEMV, GEMM, Softmax, MaxReduce, SumReduce, Transpose; 掌握访存合并、向量化访存等 IO-Bound 优化技巧, 以及 Tiling 等 Latency-Bound 优化技巧

个人介绍

本人拥有 两年全职 开发经验, 具备一定工程意识; 个人创立开发并运营过用户数 10w+ 的微信小程序 GrowYumi; 性格开朗, 沟通配合顺畅, 大学期间组过乐队、拿过校足球冠军; 希望有机会融入新的团队, 和大家一起进步。